

CORRECTION DES TRAVAUX DIRIGÉS DE
MACHINE LEARNING
CYCLE PLURIDISCIPLINAIRE D'ÉTUDES SUPÉRIEURES
UNIVERSITÉ PARIS SCIENCES ET LETTRES

Joon Kwon

vendredi 20 mars 2020



EXERCICE 1. — On rappelle que pour $f \in \mathcal{F}(\mathcal{X}, \mathcal{Y})$:

$$R(f) = \mathbb{E}[\ell(Y, f(X))] = \mathbb{E}[\mathbb{1}_{Y \neq f(X)}],$$

où la second égalité est valable ici car on considère la fonction de perte 0–1.

1) On pose $f_*(x) = \begin{cases} 1 & \text{si } x \geq 1/2 \\ 0 & \text{sinon.} \end{cases}$. Alors étant donné la distribution P , on a toujours $f_*(X) = Y$. Montrons que f_* minimise bien le risque. On calcule son risque :

$$R(f_*) = \mathbb{E}[\underbrace{\mathbb{1}_{\{Y \neq f_*(X)\}}}_{=0}] = 0.$$

Pour tout prédicteur $f \in \mathcal{F}(\mathcal{X}, \mathcal{Y})$,

$$R(f) = \mathbb{E}[\underbrace{\mathbb{1}_{\{Y \neq f(X)\}}}_{=0 \text{ ou } 1}] \geq 0 = R(f_*).$$

Donc, f_* minimise bien le risque, autrement dit :

$$R(f_*) = \min_{f \in \mathcal{F}(\mathcal{X}, \mathcal{Y})} R(f).$$

- 2) On pose $f_*(x) = 1$ pour tout $x \in \mathcal{X}$ et montrons que f_* minimise le risque.
On a,

$$\begin{aligned} R(f_*) &= \mathbb{E} [\mathbb{1}_{\{Y \neq f(X)\}}] = \mathbb{E} [\mathbb{1}_{\{Y \neq 1\}}] \\ &= \mathbb{P}[Y \neq 1] = 1 - \mathbb{P}[Y = 0] \\ &= \frac{1}{3} \end{aligned}$$


Pour $f \in \mathcal{F}(\mathcal{X}, \mathcal{Y})$,

$$\begin{aligned} R(f) &= \mathbb{E} [\mathbb{1}_{\{Y \neq f(X)\}}] = \mathbb{P}[Y \neq f(X)] \\ &= \mathbb{P}[Y \neq f(X) \text{ et } f(X) = 1] + \mathbb{P}[Y \neq f(X) \text{ et } f(X) = 0] \\ &= \mathbb{P}[Y = 0 \text{ et } f(X) = 1] + \mathbb{P}[Y = 1 \text{ et } f(X) = 0] \\ &= \mathbb{P}[Y = 0] \mathbb{P}[f(X) = 1] + \mathbb{P}[Y = 1] \mathbb{P}[f(X) = 0] \\ &\geq \frac{1}{3} (\mathbb{P}[f(X) = 1] + \mathbb{P}[f(X) = 0]) \\ &= \frac{1}{3}. \end{aligned}$$

où on a pu passer à la quatrième ligne car X et Y sont indépendants. On a donc bien

$$R(f_*) = \min_{f \in \mathcal{F}(\mathcal{X}, \mathcal{Y})} R(f).$$

EXERCICE 2. — On représente graphiquement l'échantillon d'apprentissage.



Pour $k = 1$, le découpage de l'ensemble d'entrées est donné par :

$$\begin{aligned} [0, 10] &= \underbrace{A_{\{1\}}^{(1)}}_{=[0, 3/2]} \sqcup \underbrace{A_{\{2\}}^{(1)}}_{=[3/2, 7/2]} \sqcup \underbrace{A_{\{3\}}^{(1)}}_{=[7/2, 5]} \sqcup \underbrace{A_{\{4\}}^{(1)}}_{=[5, 15/2]} \sqcup \underbrace{A_{\{5\}}^{(1)}}_{=[15/2, 10]}, \end{aligned}$$

où on rappelle que chaque $A_{\{m\}}^{(1)}$ pour $m \in [5]$ correspond à l'ensemble des $x \in [0, 10]$ pour lesquels x_m est le plus proche voisin (au sens de la première statistique de rang). Pour tout $m \in [5]$ et $x \in A_{\{m\}}^{(1)}$, on a $\hat{f}^{(1)}(x) = y_m$, ce qui donne après simplification :

$$\hat{f}^{(1)}(x) = \begin{cases} 0 & \text{si } x \leq 3/2 \\ 1 & \text{si } 3/2 < x \leq 5 \\ 0 & \text{si } x > 5, \end{cases}$$

On procède de même pour les autres prédicteurs.

$$\hat{f}^{(2)}(x) = \begin{cases} 0 & \text{si } x \leq 2 \\ 1 & \text{si } 2 < x \leq 9/2 \\ 0 & \text{si } x > 9/2, \end{cases}$$

$$\hat{f}^{(5)}(x) = 0, \quad \forall x \in \mathcal{X}.$$

Le calcul des erreurs d'apprentissage donne :

$$\varepsilon_{\text{train}}(\hat{f}^{(1)}) = \varepsilon_{\text{train}}(\hat{f}^{(2)}) = 0 \quad \varepsilon_{\text{train}}(\hat{f}^{(5)}) = \frac{2}{5}.$$

